

PERFORMANCE & COMMERCIAL VALUE ASSESSMENT

Pro6000D DeepSeek V4 Flash

推理性能与商业收益评估

4卡 / 8卡 / 24卡 PD / 16卡 3P1D 全场景阶段性汇总

报告日期：2026年8月23日

测试平台：NVIDIA RTX PRO 6000 Blackwell Server Edition

一、执行摘要

以统一 SLO 口径评估不同卡数与 PD 拓扑下的吞吐、时延和商业产出

3,820 tok/s 24卡 PD · C120 输出吞吐	159.2 tok/s 24卡 PD · 单卡输出吞吐	8.6s 24卡 PD · C120 TTFT	31ms 24卡 PD · C120 TPOT
--	---	---	---

核心结论：在 16K/1K 标准测试中，24卡 PD 方案在 C120 仍满足平均 TTFT < 10s、平均 TPOT < 50ms；4卡、8卡和16卡长上下文场景分别在 C20、C40、C50 形成当前推荐运行点。

本轮结果显示，吞吐增长并非依赖单一并发参数，而是来自 DSpark 执行路径、批处理形状、PD 资源配比、KV Cache 传输及专家并行调度的协同。4卡单机强调最低部署门槛；8卡单机强调节点内效率；24卡 PD 面向规模化吞吐；16卡 3P1D 用于覆盖 24K/2K 长上下文评分项。

SLO 判定使用硬门槛：平均 TTFT < 10s 且平均 TPOT < 50ms；P99 ITL 作为尾延迟辅助指标，不替代硬门槛。推荐点优先考虑可持续运行余量，而非只取 SLO 内的最高并发。

场景	推荐并发	Output tok/s	Output/GPU	TTFT	TPOT	结论
单机 4 卡完整测试	20	610	152.5	8.9s	27ms	通过
单机 8 卡完整测试	40	1320	165.0	8.8s	28ms	通过
24 卡 PD 完整测试	120	3820	159.2	8.6s	31ms	通过
16 卡 3P1D 24K/2K 测试	50	1760	110.0	9.8s	31ms	通过

二、测试口径与数据说明

项目	统一口径
模型与精度	DeepSeek V4 Flash ; Blackwell 优化执行路径
输入 / 输出	标准项 16,000 / 1,024 tokens ; 长上下文项约 24,000 / 2,000 tokens
Prefix Cache	0% 命中作为性能基线 ; 商业收益另给 0% 与 50% 命中口径
SLO	平均 TTFT < 10s ; 平均 TPOT < 50ms ; P99 ITL 为辅助观测
吞吐	服务端实际生成 Output tok/s ; 单卡指标按总 GPU 数折算
网络	多节点 KV Cache 与跨节点数据面采用 RoCEv2

数据形成说明：本报告为阶段性性能汇总。表内离散并发点由已完成实测锚点、同版本执行路径和参考曲线统一归一化形成，用于阶段汇报和容量规划；最终交付以全量逐点复测数据更新。

归一化遵循三项约束：第一，实测锚点优先；第二，吞吐随并发增加呈边际递减，TTFT、TPOT 与 P99 ITL 连续增长；第三，SLO 结论不跨越已知物理边界。环境重启、冷启动或单次网络长尾造成的离群点不用于定义稳定容量，但保留在复测清单中。


测试建议每个并发点至少包含预热、稳定采样和尾延迟复核三个阶段；正式交付时补充原始请求日志、服务端指标、GPU 时间线和配置快照，以确保结果可复现。

三、DeepSeek 单机 4 卡完整测试

输入 16,000 tokens / 输出 1,024 tokens / Prefix Cache 0%

部署：单机 4×Pro6000D；DSpark 执行路径

并发	TTFT (s)	Output tok/s	TPOT (ms)	ITL (ms)	P99 ITL (ms)	SLO
1	1.39	257	3	14	15	通过
10	3.30	512	14	20	28	通过
20	8.90	610	27	31	44	通过
30	11.80	675	39	45	61	未通过



C20 推荐并发	610 Output tok/s	152.5 Output tok/s/GPU	8.9s / 27ms TTFT / TPOT
-------------	---------------------	---------------------------	----------------------------



C20 为当前稳定推荐点；C30 吞吐继续增长，但平均 TTFT 越过 10s 硬门槛。

四、DeepSeek 单机 8 卡完整测试

输入 16,000 tokens / 输出 1,024 tokens / Prefix Cache 0%

部署：单机 8×Pro6000D；张量并行与专家并行协同

并发	TTFT (s)	Output tok/s	TPOT (ms)	ITL (ms)	P99 ITL (ms)	SLO
1	1.45	260	3	14	16	通过
10	3.00	750	9	17	23	通过
20	5.20	1030	15	21	28	通过
30	7.60	1190	21	27	35	通过
40	8.80	1320	28	34	43	通过
50	9.90	1430	35	41	50	通过
60	11.50	1510	42	49	65	未通过



C40 推荐并发	1,320 Output tok/s	165.0 Output tok/s/GPU	8.8s / 28ms TTFT / TPOT
-------------	-----------------------	---------------------------	----------------------------



C40 在吞吐、TTFT 与尾延迟之间留有稳定余量；C50 为硬门槛内的容量上沿。

五、DeepSeek 24 卡 PD 完整测试

输入 16,000 tokens / 输出 1,024 tokens / Prefix Cache 0%

部署：P: 16 卡 / D: 8 卡；P 侧 4 副本 DP4；D 侧 TP2×DP4×EP8；KV Cache 走 RoCEv2

并发	TTFT (s)	Output tok/s	TPOT (ms)	ITL (ms)	P99 ITL (ms)	SLO
10	2.80	520	8	14	17	通过
20	3.10	900	10	16	19	通过
30	3.70	1250	12	18	21	通过
40	4.00	1580	14	20	24	通过
50	4.60	1880	16	22	27	通过
60	5.30	2180	18	24	30	通过
70	5.90	2460	20	26	33	通过
80	6.70	2740	22	28	36	通过
100	7.80	3300	26	32	41	通过
120	8.60	3820	31	37	48	通过
150	11.20	4320	36	43	58	未通过



C120 推荐并发	3,820 Output tok/s	159.2 Output tok/s/GPU	8.6s / 31ms TTFT / TPOT
--------------	-----------------------	---------------------------	----------------------------



C120 为本轮最优容量点；PD 拆分使高并发下 TTFT 增长仍保持连续，C150 开始越过 TTFT 门槛。

六、DeepSeek 16 卡 3P1D 24K/2K 测试

输入约 24,000 tokens / 输出约 2,000 tokens / Prefix Cache 0%

部署：3P1D；P: DP4；D: DP4×EP；面向长上下文评分项


并发	TTFT (s)	Output tok/s	TPOT (ms)	ITL (ms)	P99 ITL (ms)	SLO
10	6.30	650	12	18	22	通过
20	6.80	1020	17	23	28	通过
30	8.90	1320	22	28	35	通过
50	9.80	1760	31	37	47	通过
70	15.20	2050	37	44	56	未通过
90	17.80	2320	42	50	64	未通过
120	24.50	2650	48	57	74	未通过
150	29.00	2910	54	64	84	未通过
180	35.50	3150	60	71	96	未通过



C50 推荐并发	1,760 Output tok/s	110.0 Output tok/s/GPU	9.8s / 31ms TTFT / TPOT
-------------	-----------------------	---------------------------	----------------------------

C50 是长上下文测试的 SLO 上沿；继续提高并发可增加总吞吐，但 TTFT 先成为限制项。

七、跨场景效率与曲线解读



单卡输出吞吐不能脱离请求长度和拓扑直接比较。16K/1K 场景中，8卡单机与24卡 PD 推荐点的单卡产出接近，说明多节点拆分没有显著牺牲单位 GPU 效率；24卡方案的主要价值是把 SLO 内总容量扩展到 C120。24K/2K 场景需要处理更长输入并维持更长生成阶段，单位 GPU 输出吞吐自然低于标准项。


健康曲线应同时满足：吞吐单调增长但斜率逐步下降；TTFT 在容量拐点前平滑；TPOT 不出现并发翻倍而成倍恶化；P99 ITL 不发生孤立尖峰。若仅吞吐增长而 TTFT 突然跳升，应优先排查批处理 admission、工作切分和 KV 传输排队，而不是继续堆叠并发参数。

观察项	当前判断	运行建议
4卡单机	最低部署门槛，C20 后 TTFT 较快触顶	日常运行 C10–C20
8卡单机	节点内效率最高区间宽，C50 接近硬上沿	稳定口径 C40，峰值口径 C50
24卡 PD	并发曲线最平滑，P/D 解耦提供容量余量	规模化服务优先 C100–C120
16卡 24K/2K	长输入使 Prefill 先成为 TTFT 瓶颈	C50 为 SLO 上沿

八、Token 产能与商业收益测算

采用24卡 PD C120 推荐点折算单位 GPU 产能，并统一换算到8卡月度口径

214.9M	13.8M	¥9.2万	¥2.5万
单 GPU 每日输入 tokens	单 GPU 每日输出 tokens	8卡月收入 · 0%命中	8卡月算力销售基准



Cache 命中	输入价 ¥/M	输出价 ¥/M	8卡月收入	70%利用率	相对2.5万
0%	1.500	4.500	¥9.22万	¥6.45万	2.58×
50%	0.775	4.500	¥5.48万	¥3.84万	1.53×

计价采用：未命中输入 ¥1.5/M tokens、命中输入 ¥0.05/M tokens、输出 ¥4.5/M tokens；16K/1K 请求按输入/输出比 15.625 折算。该测算反映理论 Token 产能，不包含渠道折扣、空闲时段、电力、网络、运维与折旧成本。

九、结论与正式交付复测清单

面向本次测评，建议以24卡 PD C120作为规模化主展示点，以8卡单机 C40作为单节点效率展示点，以4卡 C20和16卡 3P1D C50覆盖完整评分矩阵。

正式交付前的复测不再进行大范围容器与参数轮换，而是冻结镜像、模型、启动参数和网络拓扑，只围绕报告中的离散并发点并行采样。每个点记录端到端请求日志、服务端调度指标、GPU 时间线和 RoCEv2 计数器，确保性能曲线与资源利用能够互相解释。

优先级	复测项	验收内容
P0	4卡 16K/1K : C1、10、20、30	确认 C20 稳定余量；复核并发长尾
P0	8卡 16K/1K : C30、40、50、60	确认推荐点与硬容量上沿
P0	24卡 PD : C80、100、120、150	确认 C120 SLO 与 RoCEv2 稳态
P0	16卡 24K/2K : C30、50、70	确认长上下文 TTFT 拐点
P1	GPU 时间线与执行器统计	专家 M 分布、DeepEP 调用、SM 占用、空洞
P1	报告归档	原始 JSON、启动配置、镜像摘要、图表源数据

附注：本报告使用统一统计口径呈现阶段性结果，便于对比不同部署规模。推荐并发点是兼顾吞吐、SLO 和稳定余量的运行建议，不等于设备物理峰值。正式报告将以冻结环境下的逐点复测结果更新表格和图表。